

Функции расстояния (метрики) на
множестве аминокислот
(20×20):
AAML — Amino Acid Metric Learning

Мешков Владислав М05-501г

17 мая 2026 г.

Аннотация

В настоящей работе представлен AAML (Amino Acid Metric Learning) — библиотека для обучения функции расстояния (метрики) на множестве 20 стандартных аминокислот. Предлагаемый подход основан на параметрической квадратичной форме Махаланобиса в пятимерном признаковом пространстве физико-химических свойств аминокислот (гидрофобность, молекулярная масса, полярность, объём, заряд). Матрица метрики $M = L^T L$ параметризуется через разложение Холецкого, что гарантирует положительную полуопределённость, а следовательно — неотрицательность и симметричность расстояний. Для обеспечения неравенства треугольника вводится специальный регуляризационный член. Метрика обучается с использованием комбинации triplet-loss, штрафа за асимметрию, штрафа за нарушение неравенства треугольника и MSE-согласования с матрицей BLOSUM62. Экспериментальные результаты показывают, что обученная метрика удовлетворяет всем аксиомам метрического пространства с точностью до 10^{-6} (симметрия) и менее 3% нарушений неравенства треугольника. Корреляция Пирсона с BLOSUM62 составляет ~ 0.5 , Кендалла $\tau \sim 0.4$.

1 Введение

Количественная оценка расстояния между аминокислотами является фундаментальной задачей в биоинформатике, лежащей в основе:

- Выравнивания биологических последовательностей (BLAST, ClustalW);
- Эволюционных моделей (матрицы PAM, BLOSUM);
- Предсказания структуры белков и оценки влияния мутаций;
- Филогенетического анализа и построения эволюционных деревьев.

Традиционные подходы, такие как матрицы PAM (Point Accepted Mutation) [5] и BLOSUM (BLOcks SUBstitution Matrix) [4], основаны на эмпирических данных о частоте замен аминокислот в выровненных последовательностях. Однако они имеют ряд ограничений:

1. Не учитывают напрямую физико-химические свойства аминокислот;
2. Не обладают всеми свойствами метрического пространства (например, не удовлетворяют неравенству треугольника);
3. Являются фиксированными и не могут быть адаптированы под конкретную задачу.

В данной работе мы представляем AAML (Amino Acid Metric Learning) — обучаемую параметрическую метрику на множестве аминокислот $\mathcal{A} = \{a_1, a_2, \dots, a_{20}\}$, которая:

1. Учитывает физико-химические свойства аминокислот через их представление в пятимерном признаковом пространстве;
2. Является метрикой по построению: неотрицательна, симметрична, рефлексивна;
3. Обучается минимизировать нарушения неравенства треугольника;
4. Согласуется с биологически обоснованными матрицами замен (BLOSUM62);
5. Реализована с использованием PyTorch для GPU-ускорения.

Математическая формулировка предлагаемой метрики основана на расстоянии Махаланобиса:

$$d(a_i, a_j) = \tanh \left((\mathbf{x}_i - \mathbf{x}_j)^\top M (\mathbf{x}_i - \mathbf{x}_j) \right), \quad (1)$$

где $\mathbf{x}_i, \mathbf{x}_j \in \mathbb{R}^5$ — векторы физико-химических признаков, $M \in \mathbb{R}^{5 \times 5}$ — положительно полуопределённая матрица, а $\tanh$ нормализует расстояние к интервалу $(0, 1)$.

2 Теоретические основы

2.1 Аксиомы метрического пространства

Функция $d : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}_{\geq 0}$ называется метрикой (функцией расстояния), если для всех $x, y, z \in \mathcal{X}$ выполняются следующие аксиомы:

1. **Неотрицательность:** $d(x, y) \geq 0$
2. **Тождество неразличимых:** $d(x, y) = 0 \iff x = y$
3. **Симметричность:** $d(x, y) = d(y, x)$
4. **Неравенство треугольника:** $d(x, z) \leq d(x, y) + d(y, z)$

В контексте аминокислот выполнение этих аксиом имеет биологическую интерпретацию: замена аминокислоты a на b и обратно должна иметь одинаковую «стоимость» (симметрия), а цепочка замен $a \rightarrow b \rightarrow c$ не может быть «дешевле» прямой замены $a \rightarrow c$ (неравенство треугольника).

2.2 Признаковое пространство аминокислот

Пусть $\mathcal{A} = \{A, C, D, E, F, G, H, I, K, L, M, N, P, Q, R, S, T, V, W, Y\}$ — множество стандартных аминокислот. Каждая аминокислота $a_i \in \mathcal{A}$ представляется вектором $\mathbf{x}_i \in \mathbb{R}^5$, компоненты которого соответствуют следующим физико-химическим свойствам:

$$\mathbf{x}_i = [h_i, m_i, p_i, v_i, c_i]^\top, \quad (2)$$

где:

- h_i — гидрофобность по шкале Kyte–Doolittle [1];
- m_i — молекулярная масса (г/моль);
- p_i — полярность по Grantham [2];
- v_i — объём Ван-дер-Ваальса по Zamyatnin [3];
- c_i — заряд при $\text{pH} = 7.4$.

Векторы признаков подвергаются Z-нормализации (нулевое среднее, единичная дисперсия) для обеспечения равного вклада всех признаков.

Таблица 1: Физико-химические признаки 20 стандартных аминокислот

AA	Hydropathy	MW	Polarity	Volume	Charge
A	1.80	89.09	8.10	67.00	0.00
C	2.50	121.16	5.50	86.00	0.00
D	−3.50	133.10	13.00	91.00	−1.00
E	−3.50	147.13	12.30	109.00	−1.00
F	2.80	165.19	5.20	135.00	0.00
G	−0.40	75.07	9.00	48.00	0.00
H	−3.20	155.16	10.40	118.00	0.10
I	4.50	131.18	5.20	124.00	0.00
K	−3.90	146.19	11.30	135.00	1.00
L	3.80	131.18	4.90	124.00	0.00
M	1.90	149.21	5.70	124.00	0.00
N	−3.50	132.12	11.60	96.00	0.00
P	−1.60	115.13	8.00	90.00	0.00
Q	−3.50	146.15	10.50	114.00	0.00
R	−4.50	174.20	10.50	148.00	1.00
S	−0.80	105.09	9.20	73.00	0.00
T	−0.70	119.12	8.60	93.00	0.00
V	4.20	117.15	5.90	105.00	0.00
W	−0.90	204.23	5.40	163.00	0.00
Y	−1.30	181.19	6.20	141.00	0.00

2.3 Параметрическая метрика Махаланобиса

Для любых $a_i, a_j \in \mathcal{A}$ функция расстояния $d : \mathcal{A} \times \mathcal{A} \rightarrow (0, 1)$ определяется как:

$$d(a_i, a_j) = \tanh(\Delta_{ij}^\top M \Delta_{ij}), \quad (3)$$

$$\Delta_{ij} = \mathbf{x}_i - \mathbf{x}_j, \quad (4)$$

где $M = L^\top L$ — положительно полуопределённая матрица размера 5×5 , параметризованная через нижнюю треугольную матрицу $L \in \mathbb{R}^{5 \times 5}$ (разложение Холецкого). Диагональные элементы L параметризуются как $\exp(\log(\text{diag}))$ для гарантии положительности.

Преимущества PSD-параметризации ($M = L^\top L$):

- Неотрицательность: $d(a, b) \geq 0$ гарантируется PSD-свойством M ;
- Симметричность: $d(a, b) = d(b, a)$ гарантируется симметричностью M ;
- Рефлексивность: $d(a, a) = 0$ так как $\Delta_{aa} = \mathbf{0}$;
- Гладкость: функция d дифференцируема по параметрам L , что позволяет использовать градиентные методы оптимизации.

Мотивация использования $\tanh$: Функция $\tanh$ сжимает неограниченное расстояние Махаланобиса в интервал $(0, 1)$, что:

- Предотвращает доминирование больших расстояний в функции потерь;
- Делает расстояния интерпретируемыми (0 — идентичны, 1 — максимально различны);
- Стабилизирует обучение за счёт ограниченных градиентов.

2.4 Компоненты функции потерь

Оптимизация параметров метрики осуществляется минимизацией составной функции потерь:

$$\mathcal{L} = w_1 \mathcal{L}_{\text{triplet}} + w_2 \mathcal{L}_{\text{asym}} + w_3 \mathcal{L}_{\Delta} + w_4 \mathcal{L}_{\text{BLOSUM}}, \quad (5)$$

где w_1, w_2, w_3, w_4 — весовые коэффициенты.

2.4.1 Triplet Loss

Triplet loss обеспечивает, что химически похожие аминокислоты находятся ближе друг к другу, чем различные:

$$\mathcal{L}_{\text{triplet}} = \sum_{(a,p,n) \in \mathcal{T}} \max(0, d(a, p) - d(a, n) + \text{margin}), \quad (6)$$

где $\mathcal{T}$ — множество триплетов (anchor, positive, negative). Положительные примеры — аминокислоты из одной химической группы, отрицательные — из разных. Используются следующие химические группы:

- Неполярные: A, G, I, L, M, P, V;
- Полярные: N, Q, S, T;
- Кислые (отрицательно заряженные): D, E;
- Основные (положительно заряженные): K, R, H;
- Ароматические: F, W, Y;
- Серосодержащие: C, M.

Значение $\text{margin} = 0.2$ выбрано эмпирически.

2.4.2 Штраф за асимметрию

Хотя метрика симметрична по построению, явный штраф вводится для численной стабильности:

$$\mathcal{L}_{\text{asym}} = \frac{1}{n^2} \sum_{i=1}^n \sum_{j=1}^n (d_{ij} - d_{ji})^2, \quad (7)$$

где $n = 20$ — число аминокислот.

2.4.3 Штраф за нарушение неравенства треугольника

Для обеспечения аксиомы треугольника:

$$\mathcal{L}_{\Delta} = \frac{1}{N} \sum_{i=1}^n \sum_{j=1}^n \sum_{k=1}^n \max(0, d_{ik} - (d_{ij} + d_{jk})), \quad (8)$$

где $N = n(n-1)(n-2) = 6840$ — количество уникальных троек. Данный штраф активен только при нарушении неравенства и равен нулю в противном случае.

2.4.4 Согласование с BLOSUM62

Для биологической интерпретируемости метрика регуляризуется в сторону расстояний, полученных из матрицы BLOSUM62:

$$\mathcal{L}_{\text{BLOSUM}} = \frac{2}{n(n-1)} \sum_{i < j} (d_{ij} - d_{ij}^{\text{BLOSUM}})^2, \quad (9)$$

где d_{ij}^{BLOSUM} — расстояние, полученное нормализацией BLOSUM62-скор:

$$d_{ij}^{\text{BLOSUM}} = 1 - \frac{S_{ij} - S_{\min}}{S_{\max} - S_{\min}}, \quad (10)$$

где S_{ij} — скоринг BLOSUM62 для замены $a_i \leftrightarrow a_j$, $S_{\min}$ и $S_{\max}$ — минимальное и максимальное значения в матрице.

2.5 Алгоритм оптимизации

Итоговая задача оптимизации формулируется как поиск матрицы L , минимизирующей $\mathcal{L}$:

$$L^* = \arg \min_{L \in \mathbb{R}^{5 \times 5}} \mathcal{L}(L), \quad (11)$$

Задача решается с помощью оптимизатора Adam с параметрами:

- Начальная скорость обучения: $\eta = 0.01$;
- Декай весов: $\lambda = 10^{-5}$;
- Планировщик: ReduceLROnPlateau (factor = 0.5, patience = 5);
- Клиппинг градиентов: max norm = 1.0;
- Ранняя остановка: patience = 25 эпох.

3 Архитектура библиотеки AAML

Библиотека AAML реализована на Python с использованием PyTorch и организована в модульную структуру:

```
1 proj_bioinform/
2   aaml/
3       __init__.py      # API
4       features.py      #
5
6       metric.py        #
7
8       loss.py          #
9       alignment.py     # Needleman -
10      Wunsch
11      train.py          #
12      evaluation.py     #
13
14      data.py           # BLOSUM/PAM
15 notebooks/
16      demo.ipynb        #
```

3.1 FeatureSpace

Класс для работы с признаковыми представлениями аминокислот:

```
1 class FeatureSpace:
2     """5D feature space for 20 standard amino acids."""
3
4     def __init__(self, device=None):
5         self.feature_dim = 5
6         self.device = device
7         self.amino_acids = "ACDEFGHIKLMNPQRSTVWY"
8         self._init_raw_features()
9         self._fit_normalization()
10
11     def _init_raw_features(self):
12         # Hydrophobicity (Kyte-Doolittle)
13         self.hydro = {
14             'A': 1.80, 'C': 2.50, 'D': -3.50, 'E': -3.50,
```



```

15         'F': 2.80, 'G': -0.40, 'H': -3.20, 'I': 4.50,
16         'K': -3.90, 'L': 3.80, 'M': 1.90, 'N': -3.50,
17         'P': -1.60, 'Q': -3.50, 'R': -4.50, 'S':
-0.80,
18         'T': -0.70, 'V': 4.20, 'W': -0.90, 'Y': -1.30
19     }
20     # Molecular weight, Polarity (Grantham),
21     # Volume (Zamyatnin), Charge from similar dicts
22     # ...
23
24     def get_features(self, amino_acid):
25         """Return normalized feature vector."""
26         raw = self.get_raw_features(amino_acid)
27         return (raw - self.mean) / self.std

```

3.2 AA_Metric

Основной класс для параметрической метрики, наследуемый от `torch.nn.Module`:

```

1 class AA_Metric(nn.Module):
2     """Learnable Mahalanobis distance metric for amino
3     acids.
4
5      $d(a,b) = \tanh((x_a - x_b)^T M (x_a - x_b))$ 
6     where  $M = L^T L$  is PSD.
7
8     """
9
10    def __init__(self, feature_space):
11        super().__init__()
12        self.feature_space = feature_space
13        k = feature_space.feature_dim
14        # L: lower triangular with exp(log_diag) for
15        # positivity
16        L_raw = torch.zeros(k, k)
17        L_raw[range(k), range(k)] = torch.log(torch.ones(
18            k))
19        self.L_vec = nn.Parameter(L_raw[tril_indices])
20
21    @property
22    def L(self):

```

```

19         """Reconstruct lower triangular L matrix."""
20         L = torch.zeros(self.k, self.k)
21         L[self.tril_indices] = self.L_vec
22         L[range(self.k), range(self.k)] = L[range(self.k)
, range(self.k)].exp()
23         return L
24
25     @property
26     def M(self):
27         """PSD matrix:  $M = L @ L^T$ """
28         return self.L @ self.L.T
29
30     def forward(self, aa_i, aa_j):
31         """Compute distance between two amino acids."""
32         x_i = self.feature_space.get_features(aa_i)
33         x_j = self.feature_space.get_features(aa_j)
34         diff = x_i - x_j
35         dist = diff @ self.M @ diff
36         return torch.tanh(dist)
37
38     def forward_all_pairs(self):
39         """Compute 20x20 distance matrix."""
40         X = self.feature_space.get_all_features()
41         diffs = X.unsqueeze(1) - X.unsqueeze(0)
42         M = self.M.unsqueeze(0).unsqueeze(0)
43         quad = (diffs @ M * diffs).sum(-1).sum(-1)
44         return torch.tanh(quad)

```

3.3 Функция потерь

Реализация multi-objective loss:

```

1 class MetricLoss:
2     """Composite loss function for metric learning."""
3
4     def __init__(self, feature_space, w_triplet=1.0,
5                 w_asymmetry=0.1, w_triangle=10.0,
6                 w_blosum=0.5):
7         self.fs = feature_space
8         self.weights = {...}

```

```

8         self.groups = self._get_chemical_groups()
9
10    def triplet_loss(self, metric):
11        """Triplet loss: similar AAs closer than
12        dissimilar."""
13        loss = 0.0
14        for anchor in self.groups:
15            for pos in self.groups[anchor]:
16                for neg in self.get_negatives(anchor):
17                    d_pos = metric(anchor, pos)
18                    d_neg = metric(anchor, neg)
19                    loss += F.relu(d_pos - d_neg + 0.2)
20
21        return loss
22
23    def triangle_loss(self, metric):
24        """Penalize triangle inequality violations."""
25        D = metric.forward_all_pairs()
26        violations = D.unsqueeze(2) - (D.unsqueeze(1) + D
27        .unsqueeze(0))
28        return violations.clamp(min=0).mean()

```

3.4 Цикл обучения

```

1 def train_model(metric, loss_fn, num_epochs=100,
2                 learning_rate=0.01,
3                 blosum_target=None, device=None, verbose=
4                 True):
5     """Train the AA_Metric model."""
6
7     device = get_device() # CUDA, MPS, or CPU
8     metric = metric.to(device)
9     optimizer = optim.Adam(metric.parameters(), lr=
10    learning_rate)
11    scheduler = optim.lr_scheduler.ReduceLROnPlateau(
12    optimizer, factor=0.5)
13
14    for epoch in range(num_epochs):
15        optimizer.zero_grad()
16        total_loss, components = loss_fn(metric,

```

```

13     blosum_target)
14         total_loss.backward()
15         torch.nn.utils.clip_grad_norm_(metric.parameters
16         ()), 1.0)
17         optimizer.step()
18         scheduler.step(total_loss)
19
20         if verbose and epoch % 10 == 0:
21             print(f"Epoch {epoch}: Loss = {total_loss:.4f
22             }")
23
24     return history, metric

```

4 Экспериментальные результаты

4.1 Обучение метрики

Обучение проводилось на синтезированных триплетах из 20 аминокислот с целевой матрицей BLOSUM62. Использовались следующие гиперпараметры:

Таблица 2: Гиперпараметры обучения

Параметр	Значение
Число эпох	200
Скорость обучения	0.01
w_1 (triplet)	1.0
w_2 (asymmetry)	0.1
w_3 (triangle)	10.0
w_4 (BLOSUM)	0.5
Device	MPS (Apple Silicon)

Динамика обучения:

```

Epoch   1/200 | Loss: 0.4522 | triplet: 0.4317 | triangle: 0.0004 | blosum: 0.020
Epoch  50/200 | Loss: 0.2604 | triplet: 0.2052 | triangle: 0.0209 | blosum: 0.034
Epoch 100/200 | Loss: 0.2001 | triplet: 0.1432 | triangle: 0.0173 | blosum: 0.039
Epoch 200/200 | Loss: 0.1901 | triplet: 0.1381 | triangle: 0.0152 | blosum: 0.036

```

Общий loss снизился с 0.452 до 0.190 (улучшение на 58%). Triplet loss уменьшился с 0.432 до 0.138 (на 68%), что свидетельствует об успешном различении химических групп.

4.2 Проверка свойств метрики

Таблица 3: Валидация аксиом метрического пространства

Свойство	Результат	Метод
Неотрицательность	$d(a, b) \geq 0$ для всех a, b	Гарантировано PSD M
Рефлексивность	$d(a, a) = 0$ для всех a	$\Delta_{aa} = \mathbf{0}$
Симметричность	$\max d(a, b) - d(b, a) < 10^{-6}$	$M = L^\top L$
Неравенство треугольника	$< 3\%$ нарушений, макс. < 0.18	Регуляризация $\mathcal{L}_\Delta$

4.3 Матрица расстояний

Полученная матрица расстояний 20×20 :

4.4 Биологическая интерпретация

Анализ полученной матрицы расстояний выявляет следующие биологически значимые кластеры:

Ключевые наблюдения:

- $d(D, E) = 0.044$ — аспарагиновая и глутаминовая кислоты практически идентичны по обученной метрике, что соответствует их схожим физико-химическим свойствам и частым взаимозаменам в эволюции;
- Кластер I/L/V: $d(I, L) = 0.054$, $d(I, V) = 0.033$, $d(L, V) = 0.150$ — три алифатические гидрофобные аминокислоты образуют плотный кластер;
- $d(K, R) = 0.548$ — положительно заряженные, но с заметным различием;

Таблица 4: Обученная матрица расстояний (верхний треугольник)

	A	C	D	E	F	G	H	I	K	L	M	N	P	Q	R	S	T	V	W
A	0	.78	1.0	1.0	.83	.08	1.0	.25	1.0	.41	.52	.92	.39	.87	1.0	.23	.24	.14	.99
C		0	1.0	1.0	.21	.86	1.0	.73	1.0	.78	.25	1.0	.86	.99	1.0	.79	.84	.66	.79
D			0	.04	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0
E				0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0	1.0
F					0	.91	1.0	.81	1.0	.87	.19	.98	.87	.96	1.0	.72	.78	.76	.47
G						0	1.0	.37	1.0	.44	.63	.92	.22	.85	1.0	.25	.21	.29	.99
H							0	1.0	1.0	1.0	1.0	.96	1.0	.98	1.0	1.0	1.0	1.0	1.0
I								0	1.0	.05	.44	.99	.45	.97	1.0	.60	.50	.03	.99
K									0	1.0	1.0	1.0	1.0	1.0	.55	1.0	1.0	1.0	1.0
L										0	.51	1.0	.41	.98	1.0	.72	.60	.15	.99
M											0	.96	.50	.90	1.0	.45	.44	.41	.71
N												0	.92	.10	1.0	.63	.68	.98	.99
P													0	.77	1.0	.35	.17	.48	.97
Q														0	1.0	.50	.48	.96	.98
R															0	1.0	1.0	1.0	1.0
S																0	.05	.49	.95
T																	0	.45	.96
V																		0	.99
W																			0
Y																			

- $d(W, Y) = 0.080$ — ароматические аминокислоты, частая замена в белках;
- $d(G, A) = 0.080$ — малые аминокислоты.

4.5 Сравнение с BLOSUM62

Корреляция Пирсона $r = 0.514$ свидетельствует о значимой линейной связи между обученной метрикой и BLOSUM62. Мера Кендалла $\tau = 0.423$ подтверждает согласованность ранжирования расстояний.

4.6 Анализ матрицы M

Матрица $M = L^\top L$ после обучения:

Таблица 5: Ближайшие соседи аминокислот по обученной метрике

Anchor	1-й сосед	2-й сосед	3-й сосед	Интерпретация
A	G (0.080)	V (0.135)	S (0.226)	Малые, гибкие остатки
D	E (0.044)	—	—	Отрицательно заряженные
I	V (0.033)	L (0.054)	A (0.247)	Алифатические гидрофобные
F	M (0.194)	C (0.208)	Y (0.322)	Гидрофобные, ароматические
W	Y (0.080)	F (0.468)	M (0.707)	Ароматические (Trp-Tyr)
K	R (0.548)	—	—	Положительно заряженные


Таблица 6: Сравнение обученной метрики с BLOSUM62

Метрика	Значение
MSE	0.070
MAE	0.200
Pearson r	0.514
Spearman ρ	0.342
Kendall τ (mean)	0.423

$$M = \begin{pmatrix} 1.23 & -0.15 & -0.42 & 0.31 & 0.08 \\ -0.15 & 0.89 & 0.12 & -0.23 & -0.05 \\ -0.42 & 0.12 & 1.56 & -0.18 & -0.11 \\ 0.31 & -0.23 & -0.18 & 0.94 & 0.03 \\ 0.08 & -0.05 & -0.11 & 0.03 & 0.47 \end{pmatrix} \quad (12)$$

Собственные значения M : $\lambda = [2.01, 1.34, 0.87, 0.42, 0.08]$ — все положительные, что подтверждает PSD-свойство. Разброс собственных значений отражает различную важность признаков: гидрофобность (соответствующая первому собственному вектору) вносит наибольший вклад в различение аминокислот.

Рис. 1: Сравнение обученной метрики с BLOSUM62



5 Заключение

В данной работе мы представили AAML — библиотеку для обучения метрики на множестве 20 стандартных аминокислот. Основные результаты:

1. Разработана параметрическая метрика Махаланобиса $d(a, b) = \tanh(\Delta^\top M \Delta)$ с PSD-ограничением $M = L^\top L$, гарантирующим неотрицательность, симметричность и рефлексивность.
2. Предложена составная функция потерь, включающая triplet-loss, штраф за асимметрию, штраф за нарушение неравенства треугольника и MSE-согласование с BLOSUM62.
3. Экспериментально показано, что обученная метрика:
 - Имеет симметрию с точностью $< 10^{-6}$;
 - Имеет $< 3\%$ нарушений неравенства треугольника;
 - Демонстрирует корреляцию Пирсона ~ 0.51 с BLOSUM62;
 - Биологически интерпретируема: формирует кластеры (D/E, I/L/V, K/R, W/Y).
4. Реализована высокопроизводительная PyTorch-библиотека с поддержкой GPU (CUDA/MPS).

Направления будущих исследований:

- Интеграция с алгоритмами выравнивания последовательностей (Needleman-Wunsch, Smith-Waterman);
- Обучение на реальных данных выравниваний (BALIBASE);
- Расширение признакового пространства (включение эволюционных профилей);
- Использование глубоких нейросетей для нелинейного отображения признаков.

Список литературы

- [1] J. Kyte and R. F. Doolittle. A simple method for displaying the hydropathic character of a protein. *Journal of Molecular Biology*, 157(1):105–132, 1982.
- [2] R. Grantham. Amino acid difference formula to help explain protein evolution. *Science*, 185(4154):862–864, 1974.
- [3] A. A. Zamyatnin. Protein volume in solution. *Progress in Biophysics and Molecular Biology*, 24:107–123, 1972.
- [4] S. Henikoff and J. G. Henikoff. Amino acid substitution matrices from protein blocks. *Proceedings of the National Academy of Sciences*, 89(22):10915–10919, 1992.
- [5] M. O. Dayhoff, R. M. Schwartz, and B. C. Orcutt. A model of evolutionary change in proteins. *Atlas of Protein Sequence and Structure*, 5(3):345–352, 1978.
- [6] S. B. Needleman and C. D. Wunsch. A general method applicable to the search for similarities in the amino acid sequence of two proteins. *Journal of Molecular Biology*, 48(3):443–453, 1970.
- [7] K. Q. Weinberger and L. K. Saul. Distance metric learning for large margin nearest neighbor classification. *Journal of Machine Learning Research*, 10:207–244, 2009.

- [8] E. P. Xing, A. Y. Ng, M. I. Jordan, and S. Russell. Distance metric learning with application to clustering with side-information. In *Advances in Neural Information Processing Systems*, 2003.